

머신러닝 및 실습

(Lecture 7)

노연수

(esnoh@koreatech.ac.kr)

Course Plan

Week	Lecture	Contents	Notes
1	-	-	대체휴일
2	파이썬 기초 I	자료형, 연산자, 조건문, 반복문	
3	파이썬 기초 II	함수, 모듈, 패키지, 클래스	
4	머신러닝이란 무엇인가?	머신러닝 기초 개념, 머신러닝 시스템의 종류 등	
5	머신러닝의 전체적인 흐름 이해하기 I	프로젝트 방향 수립, 데이터 수집, 데이터 분석	
6	머신러닝의 전체적인 흐름 이해하기 II	데이터 전처리, 모델 학습, 모델 튜닝	
7	분류모델의 이해	이진 분류기 훈련, 성능 측정, 다중 분류	
8	중간고사	-	
9	회귀모델의 이해	선형 회귀, 경사 하강법	프로젝트 공지
10	회귀모델의 확장	다항 회귀, 규제가 있는 선형 모델, 로지스틱 회귀	
11	서포트 벡터 머신의 이해	선형 SVM 분류, 비선형 SVM 분류, SVM 회귀	
12	다양한 분류 모델과 앙상블	결정 트리, 랜덤 포레스트	
13	차원 축소	차원 축소, 주성분 분석(PCA)	정상수업(5/25)
14	군집 분석	K-Means clustering	
15	프로젝트 발표	프로젝트 발표	
16	프로젝트 발표, 기말고사	기말고사	

특징 데이터의 벡터 및 행렬 표기

- ▶ n : 데이터 샘플 개수
- ▶ m : 특징 개수
- ▶ $x_j^{(i)}$: i 번째 샘플의 j 번째 특징 값(value) ($i = 1, 2, \dots, n, j = 1, 2, \dots, m$)
- ▶ $\mathbf{x}^{(i)}$: i 번째 샘플의 특징 벡터(vector), $[x_1^{(i)}, x_2^{(i)}, \dots, x_m^{(i)}]^T$
- ▶ $\mathbf{X}$: 특징 행렬(matrix)

특징 2개 ($m = 2$)

샘플 47개
($n = 47$)

i	x_1	x_2	y
1	2389	4322	123
2	374	4637	235
3	291	6942	126
$\vdots$	$\vdots$	$\vdots$	$\vdots$
47	8213	1236	568

$x_2^{(1)}$

$\mathbf{x}^{(3)} = [x_1^{(3)}, x_2^{(3)}]^T$

$\mathbf{X} = \begin{bmatrix} (\mathbf{x}^{(1)})^T \\ (\mathbf{x}^{(2)})^T \\ \vdots \\ (\mathbf{x}^{(47)})^T \end{bmatrix}$

타겟 데이터의 벡터 표기

- ▶ $y^{(i)}$: i 번째 샘플의 타겟 값(value)
- ▶ $\mathbf{y}$: 타겟 벡터(vector)

샘플 47개
($n = 47$)

타겟			
i	x_1	x_2	y
1	2389	4322	123
2	374	4637	235
3	291	6942	126
$\vdots$	$\vdots$	$\vdots$	$\vdots$
47	8213	1236	568

$y^{(2)}$

$\mathbf{y} = [y^{(1)}, y^{(2)}, \dots, y^{(47)}]^T$

특징, 타깃 쌍 데이터 표기

- ▶ $(x_j^{(i)}, y^{(i)})$: i 번째 샘플의 j 번째 특징 값과 i 번째 샘플의 타깃 값
- ▶ $(\mathbf{x}^{(i)}, y^{(i)})$: i 번째 샘플
- ▶ $(\mathbf{X}, \mathbf{y})$: 특징-타깃 쌍으로 구성된 데이터

샘플 47개
($n = 47$)

i	x_1	x_2	y
1	2389	4322	123
2	374	4637	235
3	291	6942	126
$\vdots$	$\vdots$	$\vdots$	$\vdots$
47	8213	1236	568

$(x_2^{(2)}, y^{(2)})$

$(\mathbf{x}^{(2)}, y^{(2)})$


$(\mathbf{X}, \mathbf{y})$

회귀 분석(Regression Analysis)

정의

- ▶ 입력 변수와 출력 변수 사이의 관계를 학습하여, 연속적인 출력 변수를 예측하는 방법
 - 입력 변수: 특징(feature)
 - 출력 변수: 타겟(target)


$$\text{삶의 만족도} = \theta_0 + \theta_1 \times \text{1인당 GDP}$$



선형 회귀(Linear Regression)

정의

- ▶ 입력 변수와 출력 변수 사이의 관계를 **선형 함수**로 학습하여 값을 예측하는 방법



선형 회귀(Linear Regression)

■ 선형 회귀 모델의 표현(1)

▶ 특징(feature), 가중치(weight), 편향(bias)으로 표현

- 특징(feature): 입력 변수
 - 가중치(weight): 입력 변수의 영향력을 조절하는 변수
 - 편향(bias): 상수 항 혹은 절편
- } 모델 파라미터(model parameter)

$$\hat{y} = \theta_0 + \theta_1 x_1 + \cdots + \theta_m x_m$$

- $\hat{y}$: 예측값
- x_j : j 번째 특징값
- θ_j : j 번째 모델 파라미터 ($j = 0, 1, \cdots, m$)

선형 회귀(Linear Regression)

■ 선형 회귀 모델의 표현(2)

▶ 특징 벡터, 모델 파라미터 벡터를 활용하여 표현

$$\hat{y} = \boldsymbol{\theta}^T \mathbf{x}$$

- $\mathbf{x}$: 1을 포함한 입력 특징 벡터

$$\mathbf{x} = [1, x_1, x_2, \dots, x_m]^T$$

- $\boldsymbol{\theta}$: 모델 파라미터 벡터

$$\boldsymbol{\theta} = [\theta_0, \theta_1, \theta_2, \dots, \theta_m]^T$$

선형 회귀(Linear Regression)

■ 선형 회귀 모델의 표현(3)

▶ 특징 행렬, 모델 파라미터 벡터, 타깃 벡터를 활용하여 표현

- 모든 샘플에 대해 일반화된 식

$$\hat{\mathbf{y}} = \mathbf{X}\boldsymbol{\theta}$$

- $\mathbf{X}$: 1을 포함한 입력 특징 행렬

$$\mathbf{X} = \begin{bmatrix} (\mathbf{x}^{(1)})^T \\ (\mathbf{x}^{(2)})^T \\ \vdots \\ (\mathbf{x}^{(n)})^T \end{bmatrix} = \begin{bmatrix} 1 & x_1^{(1)} & \cdots & x_m^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_m^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(n)} & \cdots & x_m^{(n)} \end{bmatrix}$$

$$\mathbf{X}\boldsymbol{\theta} = \begin{bmatrix} 1 & x_1^{(1)} & \cdots & x_m^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_m^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(n)} & \cdots & x_m^{(n)} \end{bmatrix} \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_m \end{bmatrix}$$



- $\hat{\mathbf{y}}$: 예측 벡터

$$\hat{\mathbf{y}} = [\hat{y}^{(1)}, \hat{y}^{(2)}, \dots, \hat{y}^{(n)}]^T$$




$$\hat{\mathbf{y}} = \begin{bmatrix} \theta_0 + \theta_1 x_1^{(1)} + \cdots + \theta_m x_m^{(1)} \\ \theta_0 + \theta_1 x_1^{(2)} + \cdots + \theta_m x_m^{(2)} \\ \vdots \\ \theta_0 + \theta_1 x_1^{(n)} + \cdots + \theta_m x_m^{(n)} \end{bmatrix}$$

선형 회귀(Linear Regression)

예시

▶ 특징이 1개인 선형 회귀 모델


$$\hat{y} = h_{\theta_0, \theta_1}(x) = \theta_0 + \theta_1 x$$



선형 회귀 모델의 훈련

■ 훈련 목표


- ▶ 모든 훈련 샘플 쌍 $(x^{(i)}, y^{(i)})$ 에 대해 예측값 $\hat{y}^{(i)}$ 을 타깃값 $y^{(i)}$ 에 가깝게 만들도록,
- ▶ 모델 파라미터 θ_0 과 θ_1 를 찾는 것



비용 함수(Cost function)

▶ 모델 훈련 중에 최소화 해야 하는 함수

- 회귀 모델 대표 예시: 평균 제곱 오차(MSE: Mean Squared Error)



$$\hat{y}^{(i)} = h_{\theta_0, \theta_1}(x^{(i)}) = \theta_0 + \theta_1 x^{(i)}$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (e^{(i)})^2$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (\hat{y}^{(i)} - y^{(i)})^2$$

$$J(\theta_0, \theta_1) = \frac{1}{n} \sum_{i=1}^n (h_{\theta_0, \theta_1}(x^{(i)}) - y^{(i)})^2$$

비용 함수에 대한 이해(1)

▶ 모델

$$h_{\theta_0, \theta_1}(x) = \theta_0 + \theta_1 x$$

▶ 모델 파라미터

$$\theta_0, \theta_1$$

▶ 비용 함수

$$J(\theta_0, \theta_1) = \frac{1}{n} \sum_{i=1}^n (h_{\theta_0, \theta_1}(x^{(i)}) - y^{(i)})^2$$

▶ 목표

$$\underset{\theta_0, \theta_1}{\text{minimize}} J(\theta_0, \theta_1)$$

$$h_{\theta_1}(x) = \theta_1 x$$

$$\theta_1$$

$$J(\theta_1) = \frac{1}{n} \sum_{i=1}^n (h_{\theta_1}(x^{(i)}) - y^{(i)})^2$$


$$\underset{\theta_1}{\text{minimize}} J(\theta_1)$$

비용 함수에 대한 이해(2)


▶ $\theta_1 = 1$ 인 경우

$$J(\theta_1) = \frac{1}{n} \sum_{i=1}^n (h_{\theta_1}(x^{(i)}) - y^{(i)})^2 = \frac{1}{n} \sum_{i=1}^n (x^{(i)} - y^{(i)})^2 = 0$$

$h_{\theta_1}(x)$



$J(\theta_1)$




비용 함수에 대한 이해(3)


▶ $\theta_1 = 0.5$ 인 경우

$$J(\theta_1) = \frac{1}{n} \sum_{i=1}^n (h_{\theta_1}(x^{(i)}) - y^{(i)})^2 = \frac{1}{n} \sum_{i=1}^n (0.5x^{(i)} - y^{(i)})^2 \approx 1.17$$

$h_{\theta_1}(x)$





$J(\theta_1)$



비용 함수에 대한 이해(4)

▶ $\theta_1 = 0$ 인 경우


$$J(\theta_1) = \frac{1}{n} \sum_{i=1}^n (h_{\theta_1}(x^{(i)}) - y^{(i)})^2 = \frac{1}{n} \sum_{i=1}^n (-y^{(i)})^2 \approx 4.67$$



비용 함수에 대한 이해(5)

▶ θ_1 을 어떻게 선택할까?

- 선형 회귀 모델의 훈련 목표(goal)
- $J(\theta_1)$ 이 최소가 되는 θ_1 을 선택 $\rightarrow \theta_1 = 1$





선형 회귀 모델의 훈련

비용 함수에 대한 이해(6)

▶ 선형 회귀 모델의 비용 함수는 볼록 함수(convex function)

$$h_{\theta_0, \theta_1}(x) = \theta_0 + \theta_1 x_1$$

$$J(\theta_0, \theta_1) = \frac{1}{n} \sum_{i=1}^n \left(\theta_0 + \theta_1 x_1^{(i)} - y^{(i)} \right)^2$$



θ_0, θ_1 조합이 달라도 J 값은 동일

비용 함수를 최소화하는 모델 파라미터들은 어떻게 찾을까?

▶ 정규 방정식(Normal Equation)

- 공식으로 최적의 파라미터를 찾음(해석적 방법, analytical solution)
- 특징 수가 많을 경우 계산 복잡도 증가 → 상대적으로 느림


▶ 경사 하강법(Gradient Descent)

- 반복적인 계산을 통해 파라미터를 찾음(반복적 방법, iterative solution)
- 특징 수가 많아져도 정규 방정식 보다 계산 복잡도가 낮음 → 상대적으로 빠름

$$\hat{\theta} = (X^T X)^{-1} X^T y$$

- $\hat{\theta}$: 최적 모델 파라미터
- X : 특징 행렬
- y : 타겟 벡터

<정규 방정식>



<경사 하강법>

경사 하강법(Gradient Descent)

▮ 경사 하강법 구현(Implementation)

$$h_{\theta_1}(x) = \theta_1 x_1$$

$$J(\theta_1) = \frac{1}{n} \sum_{i=1}^n (h_{\theta_1}(x^{(i)}) - y^{(i)})^2$$

Initialize θ_1 with random values

Repeat until convergence {

$$\theta_1 := \theta_1 - \eta \frac{\partial}{\partial \theta_1} J(\theta_1)$$

}

Choose θ_1 that minimize $J(\theta_1)$

① 임의의 값으로 모델 파라미터 초기화

② 비용 함수를 줄이기 위해 파라미터 업데이트
수렴 조건을 만족할 때 까지 반복
(수렴 조건 예: $J(\theta_1)$ 의 도함수가 0이 됨)



③ 비용 함수가 최소가 되는 지점의 파라미터 선택

경사 하강법(Gradient Descent)

▮ 경사 하강법에 대한 이해(1)

- ▶ 모델 파라미터에 대한 비용 함수의 편미분 만큼,
- ▶ 비용 함수가 감소하는 방향으로,
- ▶ 모델 파라미터를 조정해라

$$\theta_1 := \theta_1 - \eta \frac{\partial}{\partial \theta_1} J(\theta_1)$$





경사 하강법(Gradient Descent)

▮ 경사 하강법에 대한 이해(2)

▶ 학습률(learning rate, η)

- 모델 파라미터를 얼마나 크게 업데이트 할 지 결정하는 하이퍼파라미터
- 학습률이 너무 작으면? → 경사 하강법의 수렴 속도가 느림
- 학습률이 너무 크면? → 수렴하지 못하거나 발산(diverge)하여 최솟값을 찾지 못함

$$\theta_1 := \theta_1 - \eta \frac{\partial}{\partial \theta_1} J(\theta_1)$$




경사 하강법(Gradient Descent)

▮ 경사 하강법에 대한 이해(3)

▶ 학습률(η)을 고정해도 최솟값에 도달할 수 있음

- 최솟값 근처에서 편미분(partial derivative)이 작아짐
- 모델 파라미터 업데이트 간격(step)도 작아짐

$$\theta_1 := \theta_1 - \eta \frac{\partial}{\partial \theta_1} J(\theta_1)$$



경사 하강법(Gradient Descent)

■ 선형 회귀 모델에 대한 경사 하강법

▶ 선형 회귀 모델

$$h_{\theta_0, \theta_1}(x) = \theta_0 + \theta_1 x_1$$

▶ 선형 회귀 모델에 대한 비용 함수

$$J(\theta_0, \theta_1) = \frac{1}{n} \sum_{i=1}^n (h_{\theta_0, \theta_1}(x^{(i)}) - y^{(i)})^2$$

▶ 선형 회귀 모델의 비용 함수에 대한 경사 하강법

Repeat until convergence {

$$\theta_0 := \theta_0 - \eta \frac{2}{n} \sum_{i=1}^n (h_{\theta_0, \theta_1}(x^{(i)}) - y^{(i)})$$

$$\theta_1 := \theta_1 - \eta \frac{2}{n} \sum_{i=1}^n (h_{\theta_0, \theta_1}(x^{(i)}) - y^{(i)}) x_1^{(i)}$$

}

} θ_0, θ_1 가
동시에 업데이트

예제

▶ 선형 회귀 모델 $h_{\theta_0, \theta_1}(x)$ 의 파라미터를 경사 하강법을 이용해 최적화 하시오

θ_0, θ_1 를 임의의 값으로 초기화

수렴 조건을 만족할 때 까지 반복 {

$$\theta_0 := \theta_0 - \eta \frac{2}{n} \sum_{i=1}^n (h_{\theta_0, \theta_1}(x^{(i)}) - y^{(i)})$$

$$\theta_1 := \theta_1 - \eta \frac{2}{n} \sum_{i=1}^n (h_{\theta_0, \theta_1}(x^{(i)}) - y^{(i)}) x_1^{(i)}$$

}

$J(\theta_0, \theta_1)$ 를 최소화 하는 θ_0, θ_1 선택

■ 편미분 식 전개



$$\begin{aligned}\frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1) &= \frac{\partial}{\partial \theta_0} \frac{1}{n} \sum_{i=1}^n (h_{\theta_0, \theta_1}(x^{(i)}) - y^{(i)})^2 = \frac{\partial}{\partial \theta_0} \frac{1}{n} \sum_{i=1}^n (\theta_0 + \theta_1 x_1^{(i)} - y^{(i)})^2 \\ &= \frac{2}{n} \sum_{i=1}^n (\theta_0 + \theta_1 x_1^{(i)} - y^{(i)}) \cdot 1 \\ &= \frac{2}{n} \sum_{i=1}^n (\boldsymbol{\theta}^T \mathbf{x}^{(i)} - y^{(i)}) \cdot 1\end{aligned}$$

$$\begin{aligned}\frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1) &= \frac{\partial}{\partial \theta_1} \frac{1}{n} \sum_{i=1}^n (h_{\theta_0, \theta_1}(x^{(i)}) - y^{(i)})^2 = \frac{\partial}{\partial \theta_1} \frac{1}{n} \sum_{i=1}^n (\theta_0 + \theta_1 x_1^{(i)} - y^{(i)})^2 \\ &= \frac{2}{n} \sum_{i=1}^n (\theta_0 + \theta_1 x_1^{(i)} - y^{(i)}) \cdot x_1^{(i)} \\ &= \frac{2}{n} \sum_{i=1}^n (\boldsymbol{\theta}^T \mathbf{x}^{(i)} - y^{(i)}) \cdot x_1^{(i)}\end{aligned}$$

경사 하강법(Gradient Descent)

■ 선형 회귀 모델의 비용 함수 특징


- ▶ 볼록 함수(convex function)
- ▶ 모델 훈련 전 특징 스케일링(feature scaling)을 하지 않으면 수렴 속도가 느려짐



경사 하강법(Gradient Descent)

비용 함수의 최솟값이 여러 개인 경우


- ▶ 비용 함수가 고차원일 경우 발생
- ▶ 모델 파라미터 초기값에 따라 수렴되는 최솟값이 다를 수 있음
- ▶ 선형 회귀 모델의 비용 함수에서는 발생하지 않음



배치 경사 하강법(Batch Gradient Descent)

특징

- ▶ 훈련 데이터 전체를 이용해 파라미터가 최적값으로 수렴하게 학습
- ▶ 데이터가 큰 경우 연산 시간이 오래 걸림



<선형 회귀 모델>
(p.9 참고)

<비용 함수>


<비용 함수 편미분>

$$\hat{y}^{(i)} = \theta^T \mathbf{x}^{(i)} \quad J(\theta) = \frac{1}{n} \sum_{i=1}^n (\theta^T \mathbf{x}^{(i)} - y^{(i)})^2 \quad \frac{\partial J(\theta)}{\partial \theta_j} = \frac{2}{n} \sum_{i=1}^n (\theta^T \mathbf{x}^{(i)} - y^{(i)}) x_j^{(i)}$$

확률적 경사 하강법(Stochastic Gradient Descent, SGD)

특징


- ▶ 훈련 데이터에서 추출된 **하나의 샘플**을 활용하여 경사 하강법 적용
- ▶ 수렴 속도가 빠르고, 시스템 리소스도 적게 요구
- ▶ 최소값을 벗어날 수도 있음 → 학습률을 적절히 선택!



미니배치 경사 하강법(Mini-Batch Gradient Descent)

특징

- ▶ 훈련 데이터에서 추출된 **여러 개의 샘플(미니 배치)**을 활용하여 경사 하강법 적용
- ▶ 배치 경사 하강법의 단점과 확률적 경사 하강법의 단점 보완



실 습

실습 준비

- ▶ LMS에 업로드 된 파일 모두 다운로드
- ▶ 프로젝트 폴더 열기
- ▶ 다운로드 받은 파일들을 모두 프로젝트 폴더로 이동
- ▶ 가상환경 설정 확인
- ▶ 가상환경에 라이브러리 추가 설치 `pip install ipyml`